Trabajo Final del Módulo Principios de Estadística Computacional

Silvia Prevettoni

2025-09-24

Análisis Comparativo del Rendimiento Educativo y su Relación con Factores Socioeconómicos a partir de Datos PISA.

Introduccion

El Programa para la Evaluación Internacional de los Estudiantes (PISA, por sus siglas en inglés), coordinado por la Organización para la Cooperación y el Desarrollo Económicos (OCDE), es un estudio comparativo internacional que evalúa las habilidades y conocimientos de estudiantes de 15 años en matemáticas, lectura y ciencias. Es crucial destacar que el objetivo de PISA no es evaluar a los estudiantes de manera individual, sino valorar la eficacia de los sistemas educativos en su conjunto.

Los datos para este proyecto provienen del paquete de R "Learning Towers", que reproduce los resultados de PISA. A partir de esta base de datos, el estudio se propone responder las siguientes preguntas de investigación, centrándose en una muestra de cuatro países de diferentes continentes (Argentina, Irlanda, Corea del Sur y Nueva Zelanda).

¿Cuál es el nivel de rendimiento en las áreas evaluadas en cada uno de los países seleccionados?

¿Existe una relación lineal entre el nivel socioeconómico y cultural (ESCS) de los estudiantes y su rendimiento académico? De ser así, ¿qué tan fuerte es dicha relación?

Una vez identificada el área y el país donde esta relación es más fuerte, ¿cuál de los factores analizados (ESCS, acceso a internet, posesión de computadora, disponibilidad de habitación propia, género) ejerce una influencia más significativa sobre el rendimiento cuando se consideran de manera simultánea?

Finalmente, el proyecto concluirá con una prueba de hipótesis para evaluar si existe una diferencia estadísticamente significativa entre el rendimiento en el área de matemáticas en las pruebas del 2015 y las del 2022.

Base de Datos y sus variables

La base de estudiantes seleccionada es la de estudiantes (student) del año 2022.

Las variables son las siguientes;

- *year*: Variable de tipo numérica. Año de realización de la prueba.
- *country*: Variable de tipo factor. Expresada en codigo ISO. Hace referencia al país de origen del estudiante.
- *school_id*: Variable de tipo carácter. Indicador único de escuela.
- *student_id*: Variable de tipo numérica. Indicador único del estudiante.

- *mother_educ*: Variable de tipo factor. Nivel educativo de la madre - valores ISCED (Clasificación Internacional Normalizada de la Educación. Los valores van del ISCED 1 (Educación primaria), ISCED 2 Educación Secundaria Baja, ISCED 3 Educación Secundaria Alta, esta misma se subdivide en tres categorías (3A, 3B y 3C) según la orientación del programa y su propósito de preparación para estudios superiores y menos que ISCED 1.
- *father_educ*: Variable de tipo factor. Nivel educativo del padre. Los valores aplicados son los mismos de la variable mother_educ.
- *gender*: Variable de tipo factor. Género del estudiante. Valores masculino (259089)/femenino (260245).
- *computer*: Variable de tipo factor. Disponibilidad de computadora - valores Si/No.
- *internet*: Variable de tipo factor. Acceso a Internet - valores Si/No.
- *math*: Variable de tipo numérica. Puntajes obtenidos de los estudiantes. Valores maximo de 464 (promedio), 871 (maximo).
- *read*: Variable de tipo numérica. Puntajes obtenidos de los estudiantes. Valores maximo de 466 (promedio), 882 (maximo).
- *science*: Variable de tipo numérica. Puntajes obtenidos de los estudiantes.Valores maximo de 468 (promedio), 888 (maximo), y 25 (minimo).
- *stu_wgt*: Variable de tipo numérica. Peso final del estudiante cuya, su función es crucial para obtener resultados estadísticamente precisos que representen a toda la población estudiantil de un país, y no solo a los estudiantes que fueron muestreados.
- *desk*: Variable de tipo factor. Indica posesión de mesa de trabajo/escritorio - valores Si/No.
- *room*: Variable de tipo factor. Indica posesión de habitacion propia para el estudio - Valores Si/No.
- *dishwasher*: Variable de tipo factor. Indica posesión de lavavajillas - Valores NA.
- *television*: Variable de tipo factor. Indica cantidad de televisores.
- *computer_n*: Variable de tipo factor. Indica cantidad de computadoras.
- *car*: Variable de tipo factor. Indica cantidad de autos.
- *book*: Variable de tipo factor. Indica cantidad de libros.
- *wealth*: Variable de tipo numérica. Indica nivel de prosperidad de la familia, este indice utiliza la Teoría de Respuesta al Ítem sobre Posesiones en el hogar y Recursos educativos y Culturales.
- *escs*: Variable de tipo numérica. Índice de Estatus Social, Económico y Cultural. Analiza la equidad educativa para entender como es el estatus social, economico y cultural de las familias.

Seleccione las siguientes variables socioeconomicas y de contexto por su potencial incidencia sobre el rendimiento académico;

gender: Variable de tipo factor. Género del estudiante. Valores masculino (259089)/femenino (260245).

computer: Variable de tipo factor. Disponibilidad de computadora - valores Si/No.

internet: Variable de tipo factor. Acceso a Internet - valores Si/No.

room: Variable de tipo factor. Indica posesión de habitacion propia para el estudio - Valores Si/No.

escs: Variable de tipo numérica. Índice de Estatus Social, Económico y Cultural. Analiza la equidad educativa para entender como es el estatus social, economico y cultural de las familias.

Análisis Exploratorio

La base de datos se compone de la siguiente estructura,

```
## [1] 613744     22
```

La muestra tiene 613.744 observaciones y 22 variables.

Veamos algunos datos estadísticos;

```
##       year          country        school_id           student_id
##  Min.   :2022   ESP     : 30800   Length:613744      Min.   :  800001
##  1st Qu.:2022   ARE     : 24600   Class :character   1st Qu.:21401978
##  Median :2022   CAN     : 23073   Mode  :character   Median :39819878
##  Mean   :2022   KAZ     : 19769                      Mean   :43426434
##  3rd Qu.:2022   IDN     : 13439                      3rd Qu.:68805006
##  Max.   :2022   AUS     : 13437                      Max.   :86007492
##                 (Other):488626
##            mother_educ               father_educ        gender
##  ISCED 1         : 33110   ISCED 1         : 33507   female:305759
##  ISCED 2         : 82553   ISCED 2         : 89386   male  :307906
##  ISCED 3A        :340160   ISCED 3A        :309548   NA's  :    79
##  ISCED 3B, C     :100090   ISCED 3B, C     :112369
##  less than ISCED1: 19805   less than ISCED1: 19203
##  NA's            : 38026   NA's            : 49731
##
##  computer      internet          math            read          science
##  no  :103622   no  : 56968   Min.   :  0.0   Min.   :  0.0   Min.   :  0.0
##  yes :480021   yes :525842   1st Qu.:364.3   1st Qu.:357.2   1st Qu.:371.7
##  NA's: 30101   NA's: 30934   Median :433.1   Median :435.0   Median :444.5
##                              Mean   :440.9   Mean   :438.2   Mean   :450.5
##                              3rd Qu.:511.2   3rd Qu.:516.5   3rd Qu.:524.7
##                              Max.   :943.0   Max.   :938.7   Max.   :895.4
##
##     stu_wgt           desk          room        dishwasher    television
##  Min.   :   1.000   NA's:613744   no  :120788   NA's:613744   0   : 16523
##  1st Qu.:   5.014                 yes :459439                 1   :358112
##  Median :  12.389                 NA's: 33517                 2   :168410
##  Mean   :  46.037                                             3+  : 26856
##  3rd Qu.:  41.617                                             NA's: 43843
##  Max.   :2371.650
##
##  computer_n      car                    book            wealth
##  0   :232540   0   :135867   0-10         : 46256   Min.   : NA
##  1   :271028   1   :199079   101-200      :154182   1st Qu.: NA
##  2   : 42700   2   :163577   11-25        :132523   Median : NA
##  3+  :  8377   3+  : 87379   201-500      : 71581   Mean   :NaN
##  NA's: 59099   NA's: 27842   26-100       :117527   3rd Qu.: NA
##                              more than 500: 49167   Max.   : NA
##                              NA's         : 42508   NA's   :613744
##       escs
##  Min.   :-6.8407
##  1st Qu.:-1.0539
##  Median :-0.1845
```

```
##  Mean   :-0.3104
##  3rd Qu.: 0.5874
##  Max.   : 7.3800
##  NA's   :25468
```

Identificamos los paises relevantes para el análisis y sus areas de evaluación.

```
## # A tibble: 12 x 3
##    country Areas      Promedio
##    <fct>   <chr>         <dbl>
##  1 ARG     Matemática     389.
##  2 ARG     Lectura        413.
##  3 ARG     Ciencia        415.
##  4 IRL     Matemática     493.
##  5 IRL     Lectura        518.
##  6 IRL     Ciencia        504.
##  7 KOR     Matemática     531.
##  8 KOR     Lectura        519.
##  9 KOR     Ciencia        531.
## 10 NZL     Matemática     478.
## 11 NZL     Lectura        501.
## 12 NZL     Ciencia        505.
```

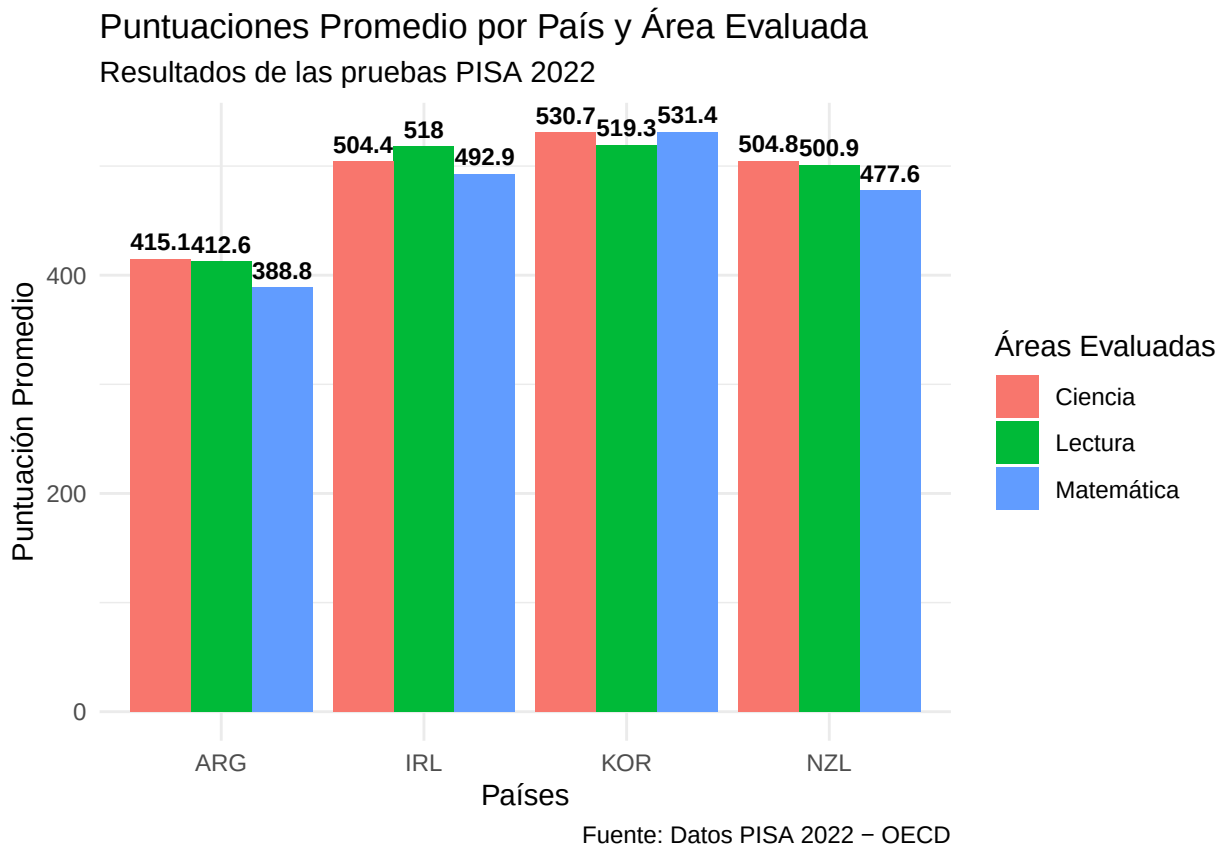


Figura 1.

La Figura 1 muestra los puntajes promedio por país y área evaluada. Se observa que Corea del Sur presenta las puntuaciones más altas en las tres áreas, mientras que Irlanda y Nueva Zelanda exhiben valores similares

entre sí. Argentina, por su parte, registra los promedios más bajos del grupo, con una diferencia notable respecto a los demás países.

A continuacion, se presenta un análisis de los resultados por paises;

Argentina

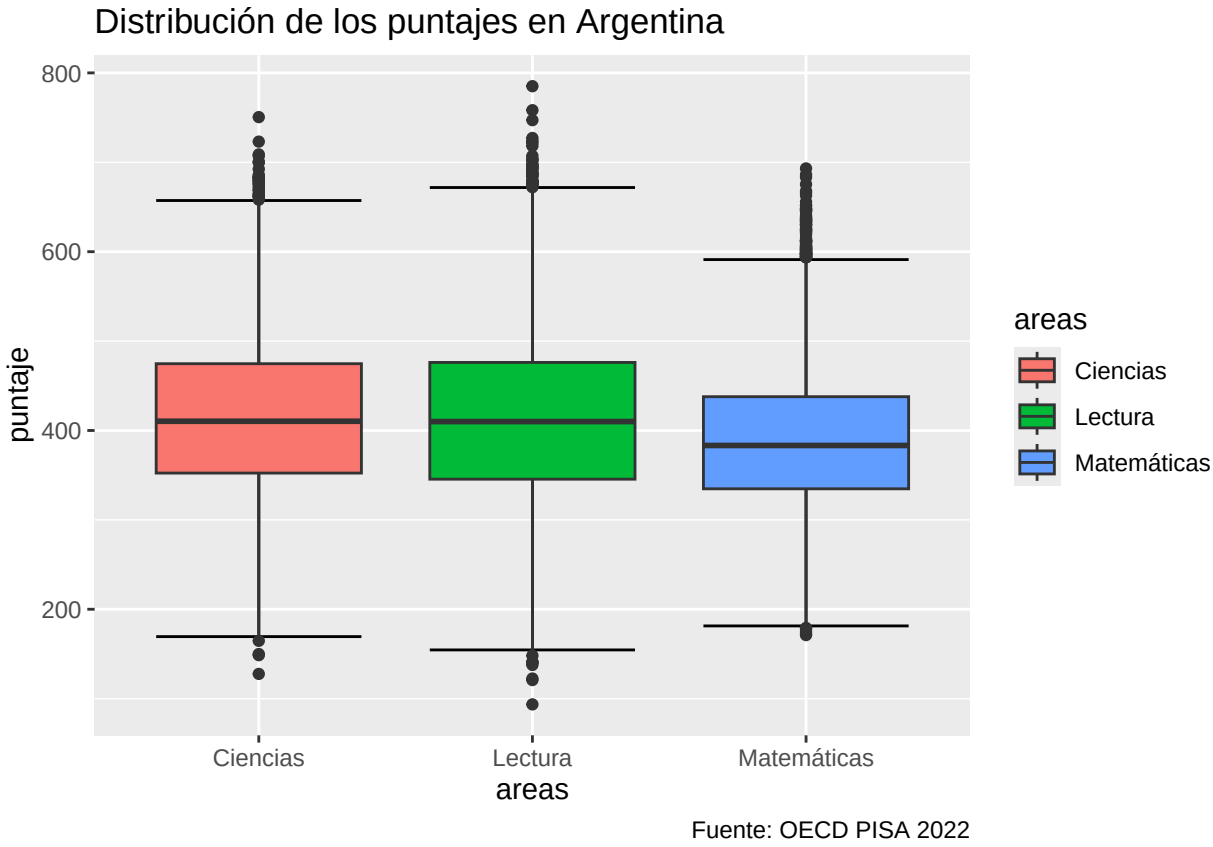


Figura 2. En el gráfico se observa que los resultados de los exámenes presentan una distribución simétrica. Ciencias y Lectura muestran la mayor variabilidad, mientras que Matemáticas tiene los datos más concentrados y presenta varios valores atípicos, especialmente en valores máximos. Las medianas de Lectura y Ciencias se ubican alrededor de los 410 puntos, y la de Matemáticas, alrededor de los 380 puntos.

Irlanda

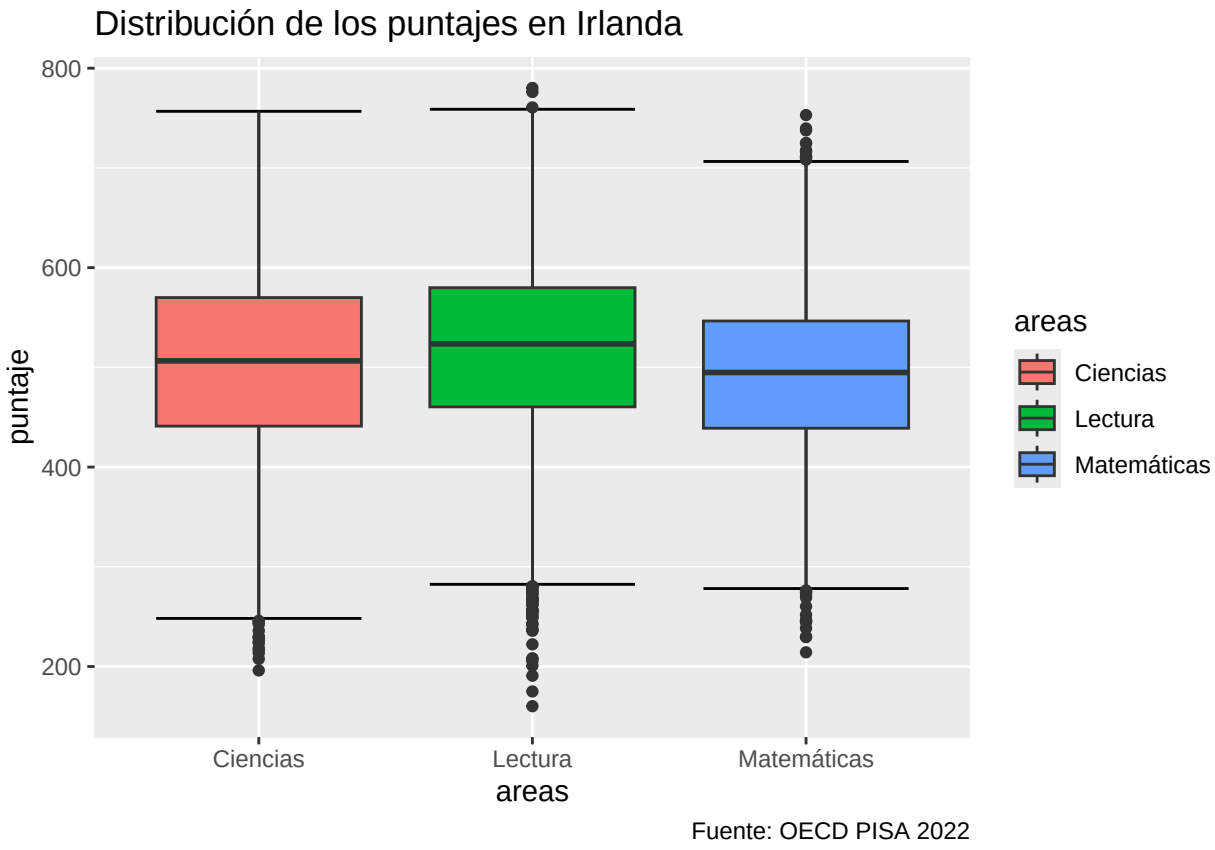


Figura 3. Distribución de puntuaciones por área evaluada. Se observa que la mediana más alta corresponde a Lectura (superior a 500 puntos), seguida por Ciencias y Matemáticas. Las tres áreas presentan distribuciones aproximadamente simétricas, aunque Matemáticas muestra una distribución ligeramente más concentrada. Tanto Lectura como Matemáticas presentan valores atípicos en ambos extremos, mientras que Ciencias solo muestra outliers en el extremo inferior.

Corea del Sur

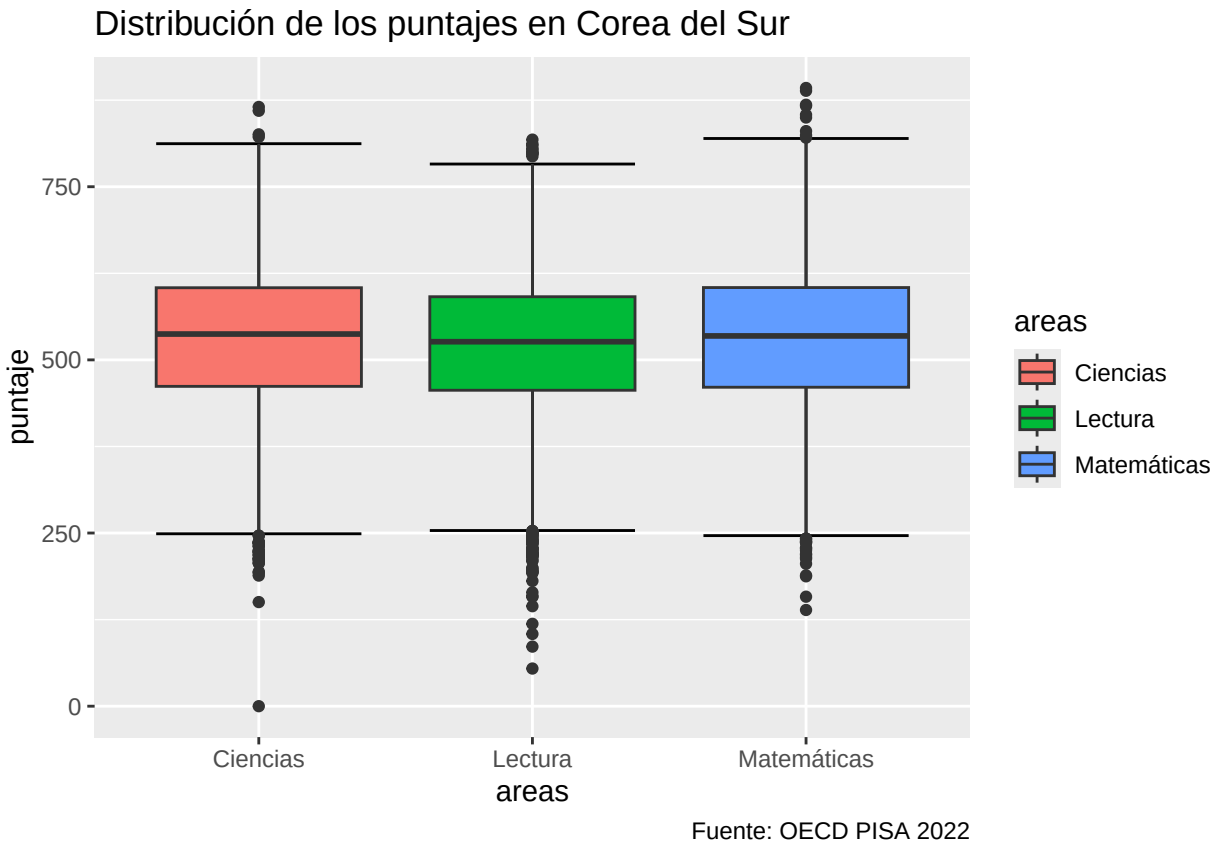


Figura 4. Distribución de puntuaciones por área. Las tres áreas evaluadas presentan distribuciones simétricas con medianas aproximadas de 525 puntos. Todas muestran valores atípicos en ambos extremos de la distribución.

Nueva Zelanda

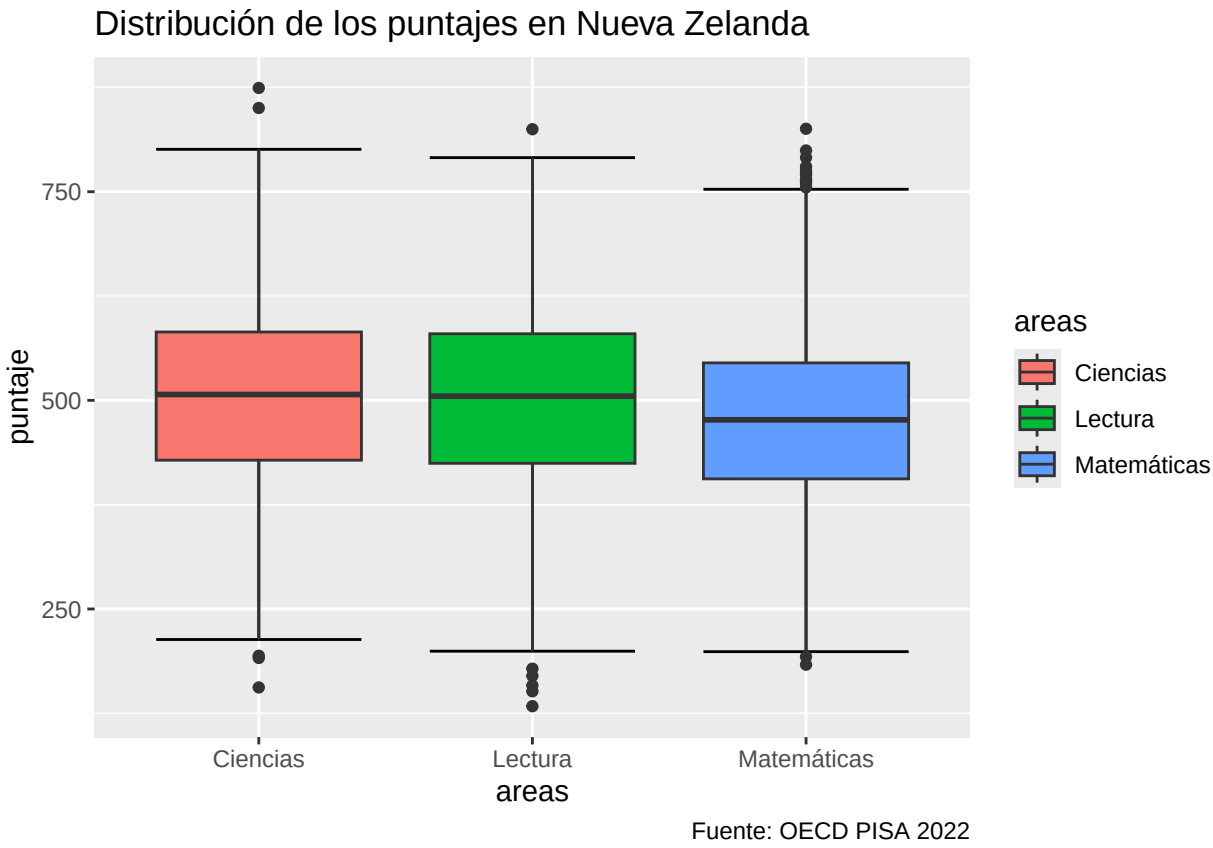


Figura 5. El análisis de los puntajes revela que tanto Ciencia como Lectura comparten una mediana de 500 puntos. Por su parte, Matemáticas presenta la mediana más baja del grupo, ubicándose por debajo de los 500 puntos.

Respecto a la dispersión de los datos, el área de Lectura es la que muestra la mayor variabilidad. Por el contrario, los resultados de Matemáticas aparecen más concentrados o menos dispersos, indicando una menor variabilidad entre los puntajes de los estudiantes.

Todas las áreas presentan valores atípicos, aunque en Ciencias son muy escasos. Lectura muestra solo un outlier en el extremo superior.

Dispersión de datos del Índice de Estatus Social, Económico y Cultural

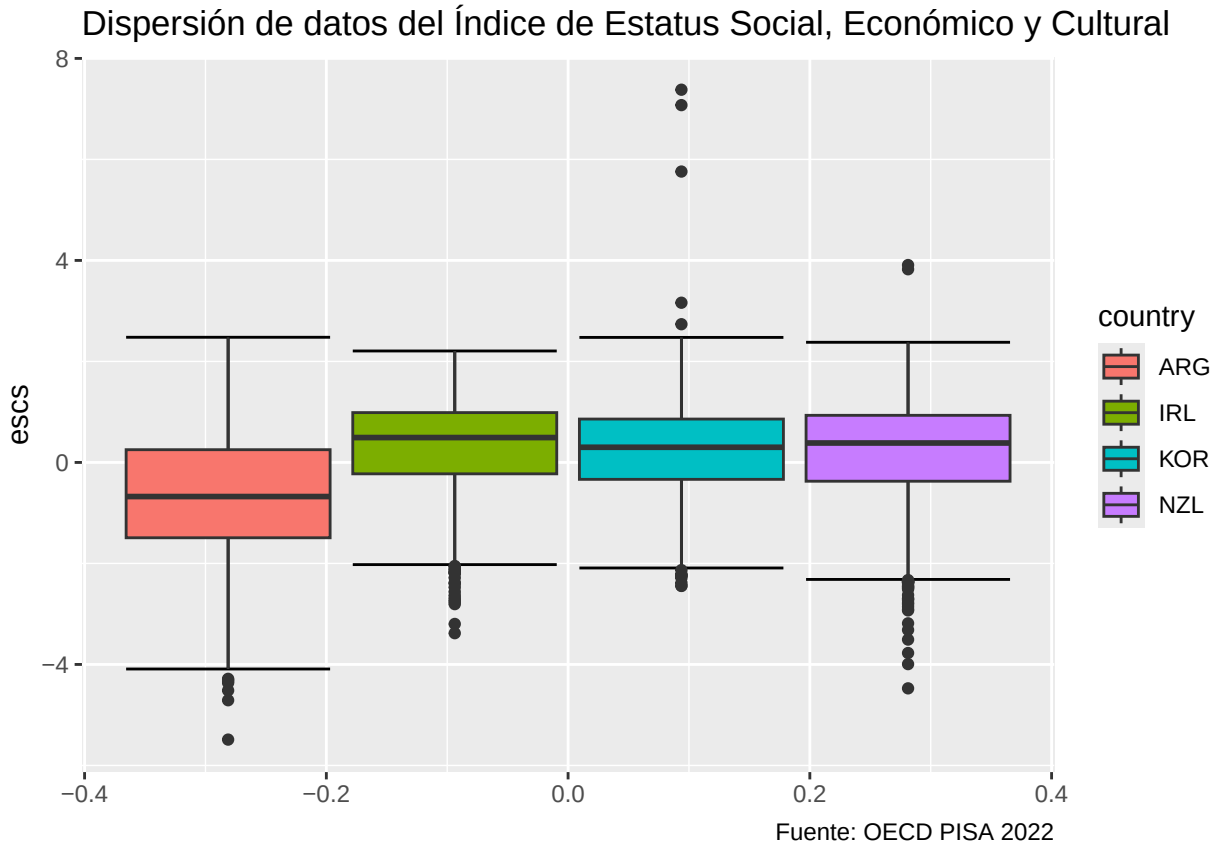


Figura 6. El gráfico permite analizar la distribución del índice de estatus social y cultural (ESCS) en los cuatro países del estudio. Se observa que Argentina presenta la mediana más baja mientras que Irlanda muestra la mediana más alta. En cuanto a la dispersión, Argentina presenta la mayor variabilidad de datos, con una distribución ampliamente dispersa. Por el contrario, Corea del Sur exhibe la distribución más concentrada alrededor de su mediana.

Respecto a la forma de las distribuciones, solo Corea del Sur muestra una distribución aproximadamente simétrica. Los otros tres países presentan sesgos en sus datos. Además, se identifican valores atípicos: Corea del Sur presenta outliers en el extremo superior de la distribución, mientras que Nueva Zelanda muestra valores atípicos en el extremo inferior.

Gráficos de Densidad

En los gráficos de densidad vemos detalladamente la forma de distribución de las puntuaciones por país.

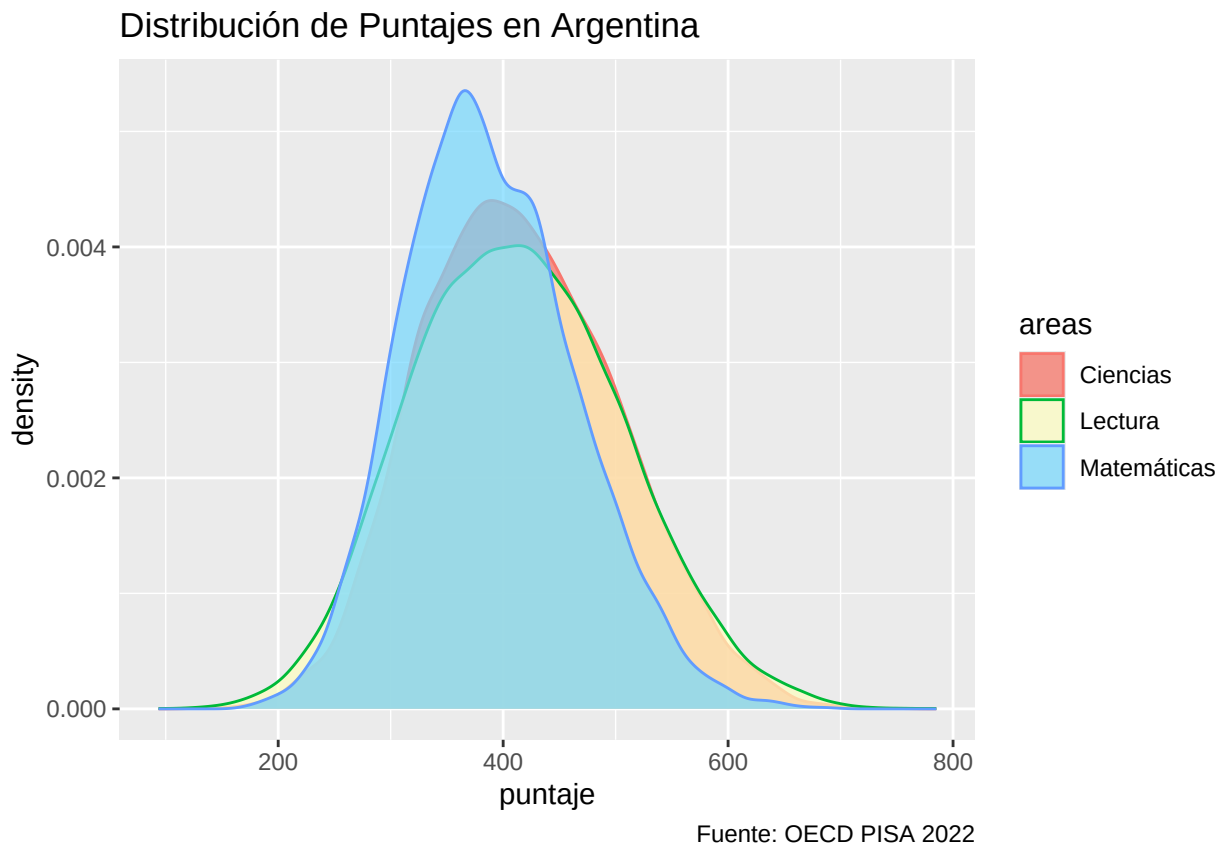


Figura 7. El gráfico muestra una asimetría positiva en el área de Matemáticas, una leve asimetría positiva en Ciencias, mientras que Lectura presenta una distribución simétrica.

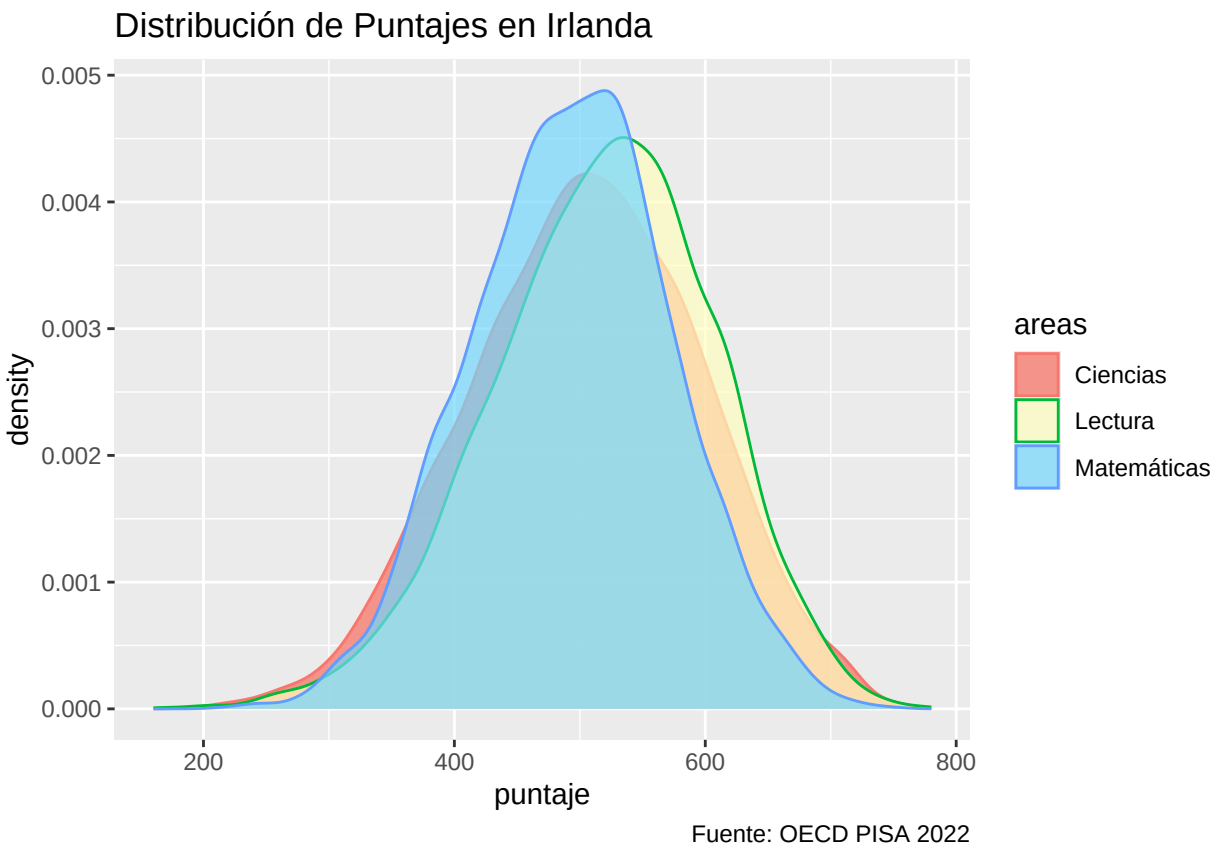


Figura 8. Distribución de puntuaciones en Irlanda. Las áreas de Ciencias y Matemáticas presentan distribuciones simétricas, mientras que Lectura muestra un leve sesgo a la izquierda (asimetría negativa).

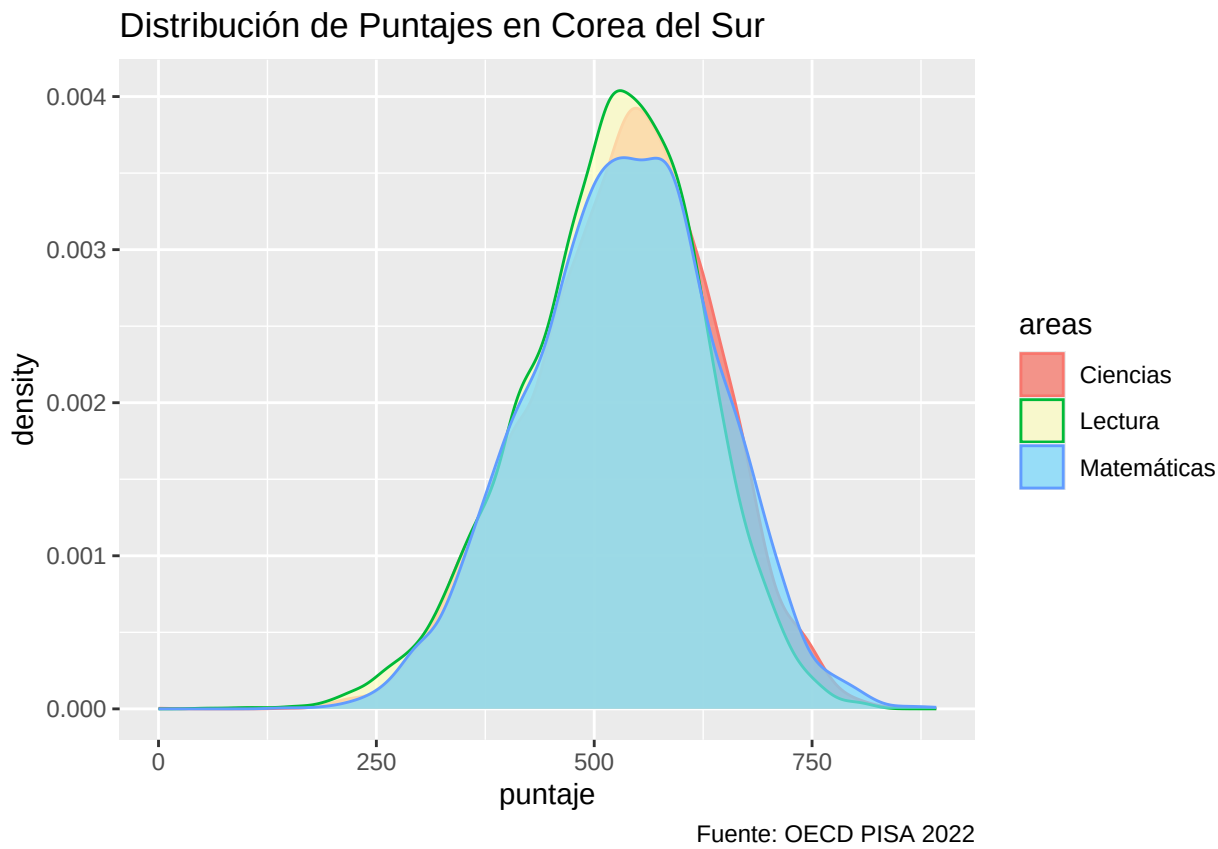


Figura 9. Distribución de puntuaciones en Corea del Sur. Los promedios presentan un leve sesgo a la izquierda (asimetría negativa) en torno a la mediana en todas las áreas.

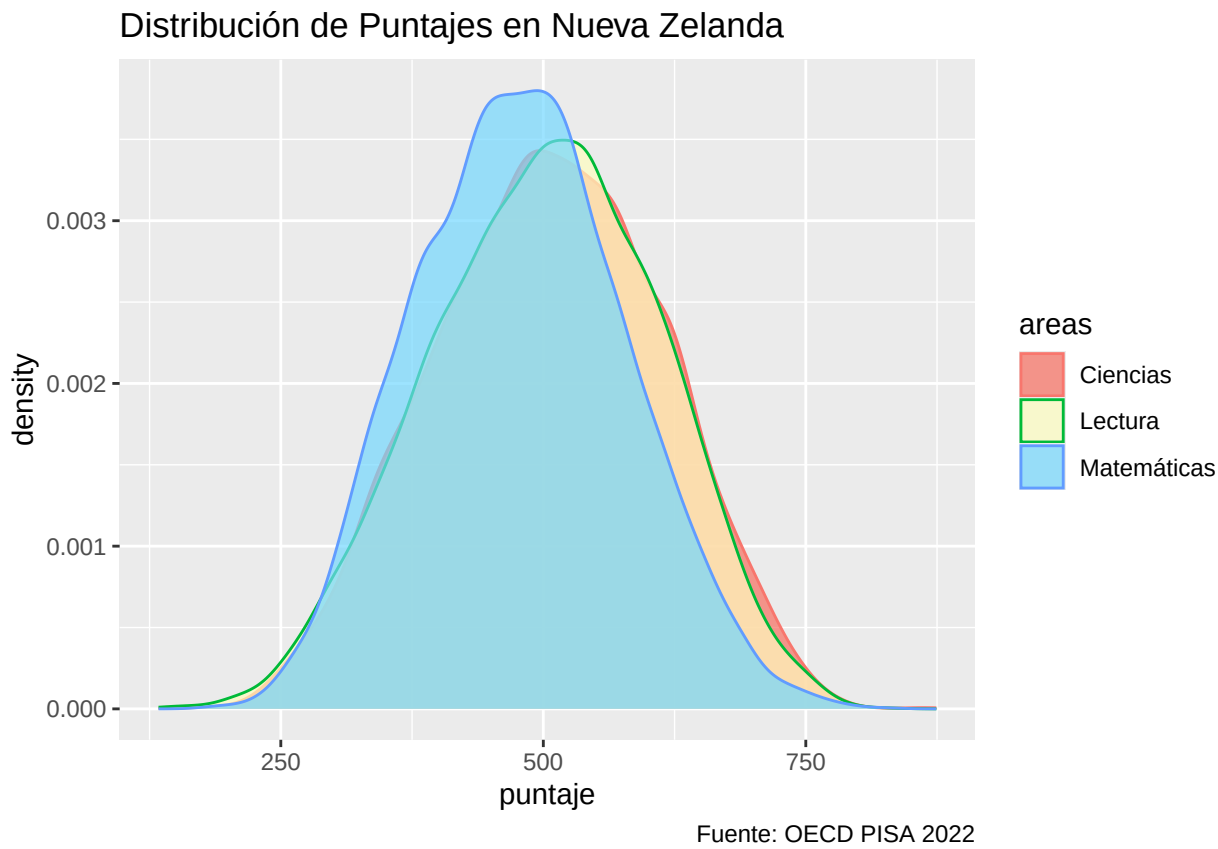


Figura 10. En Nueva Zelanda, la distribución es aproximadamente simétrica, aunque en matemáticas se observa una leve asimetría positiva (sesgo a la derecha).

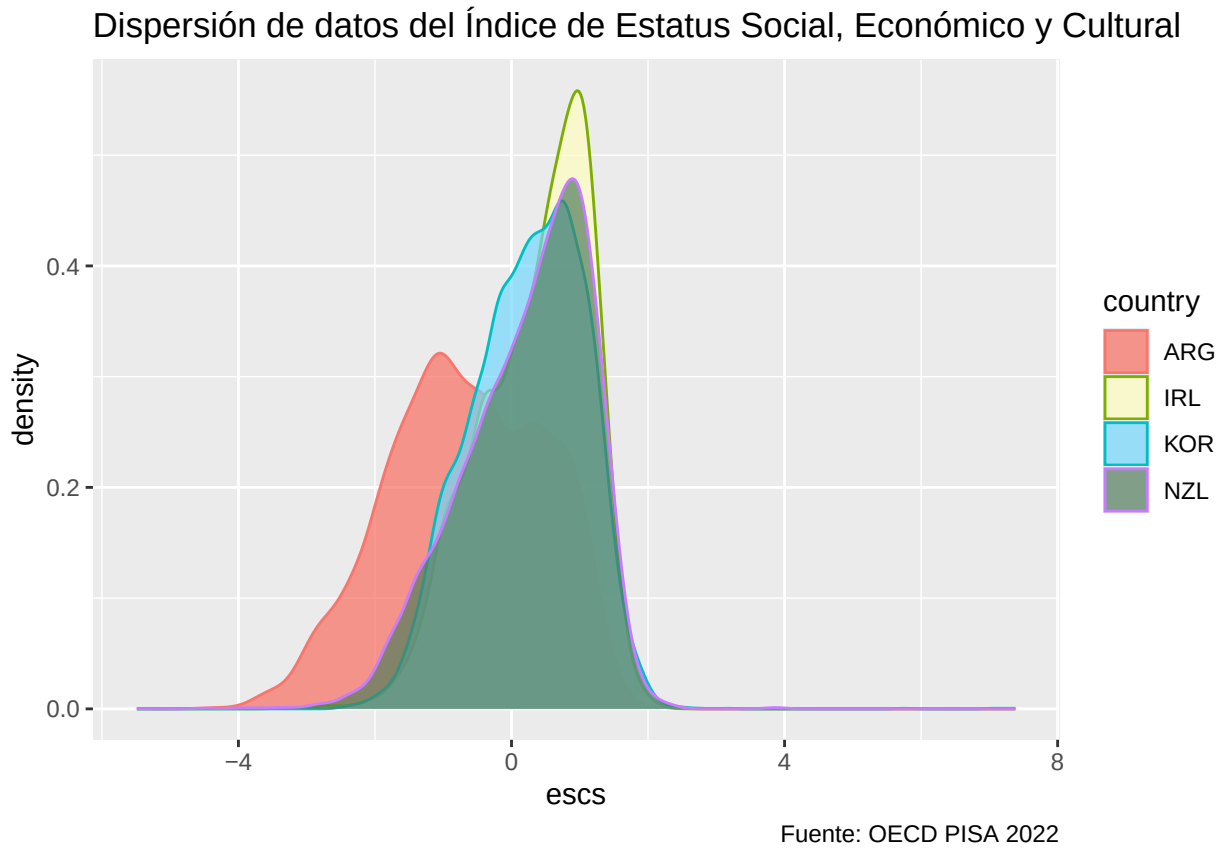


Figura 11. La distribución de puntajes en Irlanda, Corea del Sur y Nueva Zelanda presenta un sesgo a la izquierda (asimetría negativa), mientras que la distribución de Argentina muestra un sesgo a la derecha (asimetría positiva).

Análisis de Correlación entre puntuaciones y estatus socioeconomico

La correlación es fundamental porque permite identificar relaciones y realizar predicciones recordando siempre que la correlación no implica causalidad, o sea que las dos variables pueden estar correlacionadas sin que una cause la otra.

Aquí se observa que la distribución de los datos en Irlanda, Corea del Sur y Nueva Zelanda presenta una asimetría negativa, mientras que la de Argentina es positiva.

```
## # A tibble: 4 x 4
##   country matematica lectura ciencia
##   <fct>        <dbl>   <dbl>   <dbl>
## 1 ARG          0.424   0.384   0.393
## 2 IRL          0.367   0.335   0.335
## 3 KOR          0.369   0.336   0.346
## 4 NZL          0.403   0.338   0.379
```

Gráfico de Correlación

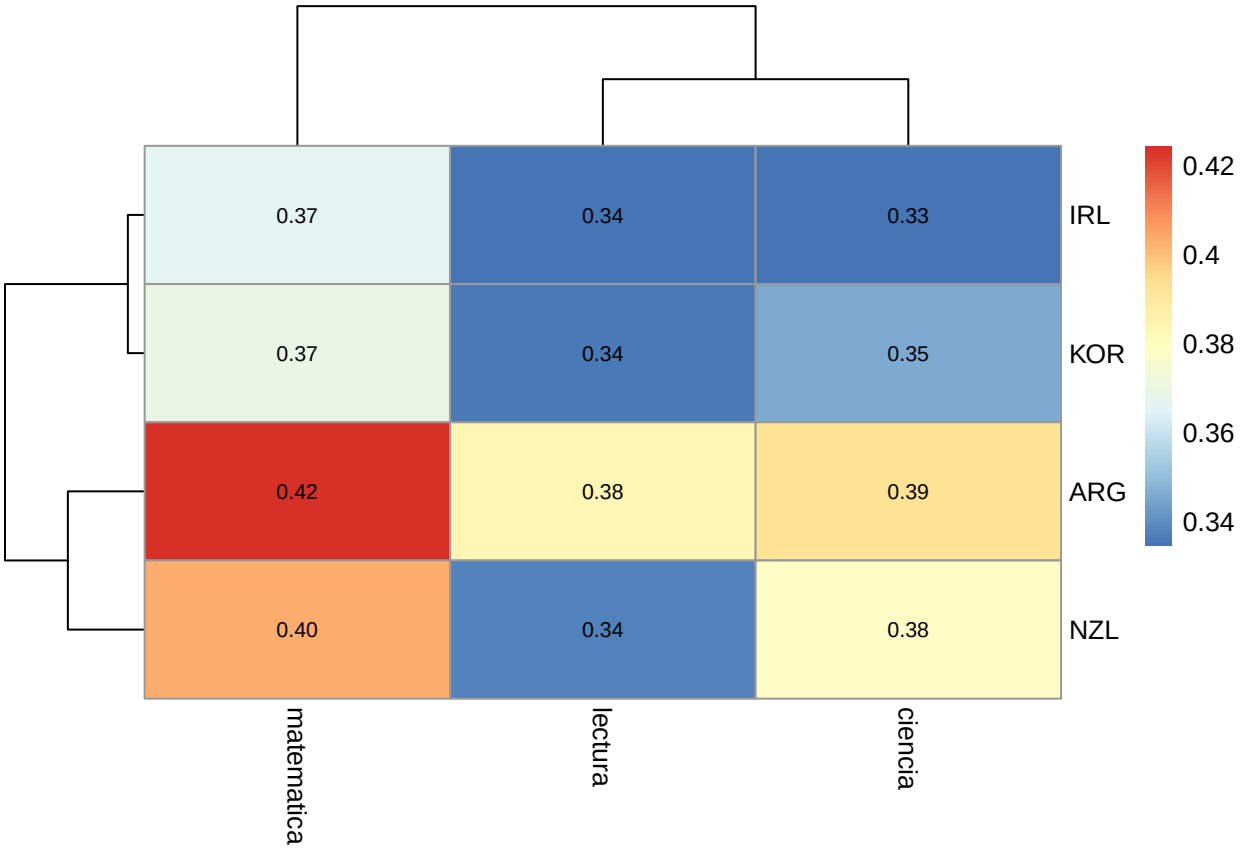


Figura 12

En la matriz de correlación de la fig. 12 se observa que todas las variables presentan correlacion positiva, revelando asociaciones más fuertes que se representan en tonos rojos, mientras que las más débiles se muestran en azul. La correlación más alta identificada es de 0.42, correspondiente a la relación entre el rendimiento en Matemáticas y el Índice de Estatus Socioeconómico y Cultural (ESCS) en Argentina. Esta correlación positiva indica que, a medida que aumenta el estatus socioeconómico, también mejora el desempeño en matemáticas. Le sigue en magnitud la correlación encontrada en Nueva Zelanda (r = 0.40), también para matemáticas. Cabe destacar que no se observaron correlaciones negativas significativas en ningún caso.

Como se evidencio previamente, Argentina presenta la correlación más fuerte entre el rendimiento en Matemáticas y el Índice de Estatus Social, Económico y Cultural (ESCS). Por lo tanto, procederemos a desarrollar un modelo de regresión lineal para analizar esta relación en profundidad.

Análisis de Regresión Lineal Simple y Visualización de Datos

De acuerdo con el punto anterior, se implementará un modelo de regresión lineal simple utilizando la variable de índice de estatus socioeconómico y cultural (ESCS) para analizar su incidencia en la puntuación del área de Matemáticas en Argentina.

```
## # A tibble: 12,111 x 7
##    country  math   escs gender internet room  computer
##    <fct>   <dbl>  <dbl> <fct>  <fct>    <fct> <fct>
##  1 ARG      395.  0.255 male   yes      yes   no
##  2 ARG      434.  0.172 female yes      yes   no
```

```
##  3 ARG      393. -1.50  female yes      no    no
##  4 ARG      337. -0.823 female yes      yes   no
##  5 ARG      496. -0.186 male   yes      no    yes
##  6 ARG      388. -1.89  female no       yes   no
##  7 ARG      313. -2.11  female <NA>     yes   <NA>
##  8 ARG      421. -1.49  male   yes      no    yes
##  9 ARG      499.  0.910 female yes      yes   yes
## 10 ARG      307. -0.363 female yes      no    yes
## # i 12,101 more rows
```

Utilizamos la funcion LM en R

```
##
## Call:
## lm(formula = math ~ escs, data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -238.518  -47.711   -0.697   45.152  273.679
##
## Coefficients:
##             Estimate Std. Error t value            Pr(>|t|)
## (Intercept) 408.3268     0.7383  553.07 <0.0000000000000002 ***
## escs         28.2063     0.5560   50.73 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 68.95 on 11717 degrees of freedom
##   (392 observations deleted due to missingness)
## Multiple R-squared:  0.1801, Adjusted R-squared:   0.18
## F-statistic:  2573 on 1 and 11717 DF,  p-value: < 0.00000000000000022
```

Calculamos los niveles de confianza.

```
## [1] 27.11654 29.29606
```

Interpretación de los coeficientes

Intercepto: Un estudiante con un nivel nulo (cero) en el índice de estatus socioeconómico y cultural (ESCS) obtiene, en promedio, una puntuación de 408.33 puntos en matemáticas.

Índice ESCS: Por cada punto que incrementa el índice ESCS, la puntuación en matemáticas aumenta en promedio 28.20 puntos, manteniendo constantes las demás variables. Con un 95% de confianza, este aumento se encuentra entre 27 y 29 puntos.

Interpretación de las Métricas del Modelo

Significancia Estadística: Todos los coeficientes son estadísticamente significativos a un nivel del 0.05, lo que indica que la relación observada difícilmente se debe al azar.

p-valor: Dado que el p-valor es menor a 0.05, se rechaza la hipótesis nula, concluyendo que el índice ESCS tiene un efecto significativo sobre el puntaje en matemáticas.

R-cuadrado ajustado (0.18): Aproximadamente el 18% de la variabilidad en los puntajes de matemáticas puede ser explicada por el índice ESCS. El 82% restante se atribuye a otros factores no incluidos en el

modelo. Se considera un poder explicativo moderado-bajo, lo cual es común en ciencias sociales donde influyen numerosas variables.

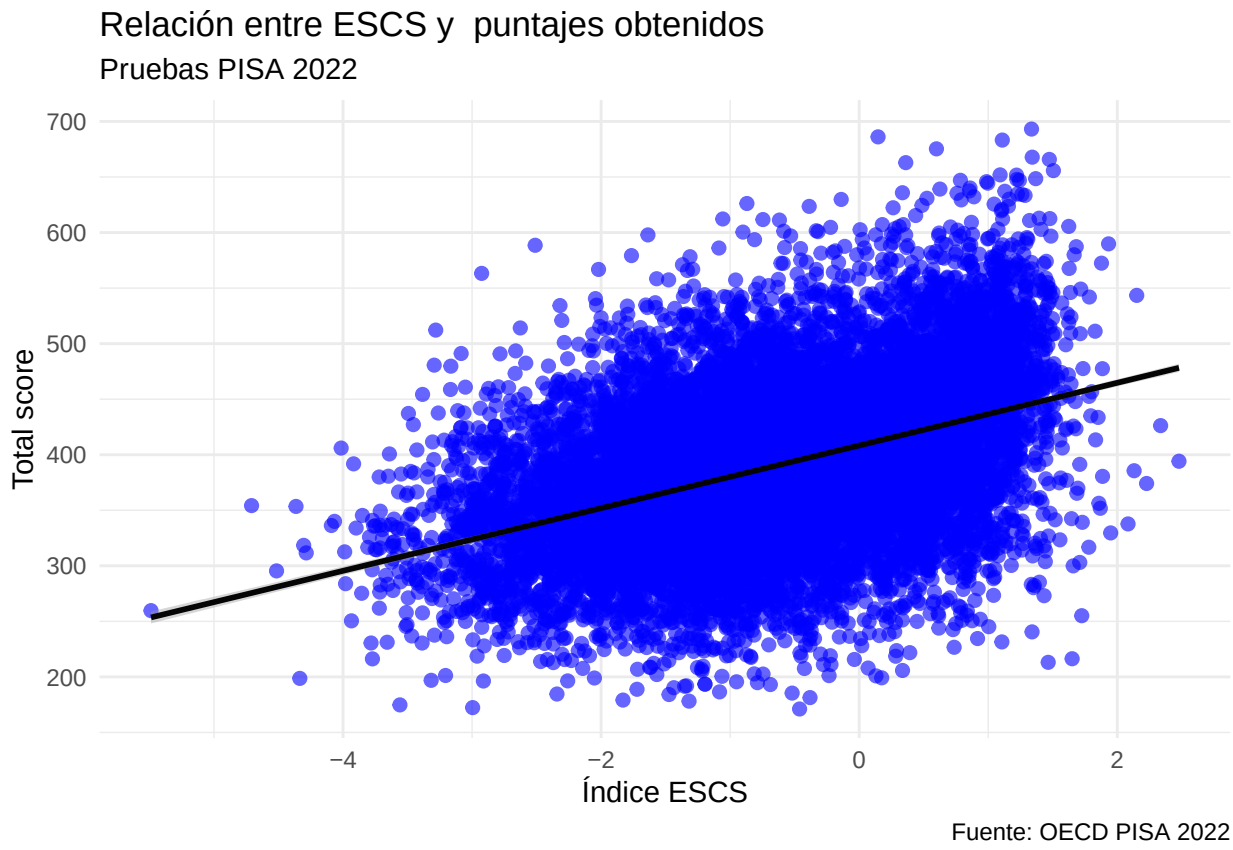


Figura 13. El gráfico muestra una relación positiva. Los coeficientes de regresión indican el cambio promedio en la variable dependiente (Y) cuando una variable independiente (X) aumenta en una unidad, manteniendo el resto de las variables constantes.

Modelo de Regresion Multiple

Adicionalmente, se implementó un modelo de regresión lineal múltiple para evaluar el impacto de un conjunto de variables predictoras sobre el rendimiento académico en Argentina.. Las variables independientes seleccionadas para el modelo son: posesión de computadora (Computer), acceso a internet (Internet), disponibilidad de habitación propia (room), índice de estatus socioeconómico y cultural (ESCS), y género del estudiante (gender). El objetivo del modelo es determinar la significancia estadística de la relación de cada una de estas variables con la variable de resultado.

```
##
## Call:
## lm(formula = math ~ escs + computer + internet + room + gender,
##     data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -248.266  -46.502   -0.726   44.872  259.144
##
## Coefficients:
```

```
##             Estimate Std. Error t value             Pr(>|t|)
## (Intercept) 381.0828     2.8763 132.493 < 0.0000000000000002 ***
## escs         25.0227     0.6468  38.684 < 0.0000000000000002 ***
## computeryes   9.8323     1.5641   6.286       0.000000000338 ***
## internetyes  21.8141     2.4601   8.867 < 0.0000000000000002 ***
## roomyes      -7.3660     1.3472  -5.468       0.000000046616 ***
## gendermale   10.5989     1.2774   8.297 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 67.45 on 11188 degrees of freedom
##   (917 observations deleted due to missingness)
## Multiple R-squared:  0.1947, Adjusted R-squared:  0.1943
## F-statistic:   541 on 5 and 11188 DF,  p-value: < 0.00000000000000022
```

Interpretación de los Coeficientes

Intercepto: Un estudiante con nivel nulo en el índice de estatus socioeconómico, sin computadora, sin internet, sin habitación propia y de género femenino, obtiene en promedio 381.08 puntos en matemáticas.

Índice de estatus socioeconómico (ESCS): Por cada punto que aumenta el índice ESCS, la puntuación en matemáticas se incrementa en 25.02 puntos en promedio, manteniendo constantes las demás variables.

Computadora: Los estudiantes con computadora obtienen 9.83 puntos más en matemáticas que aquellos sin acceso a ella, manteniendo constantes las demás variables.

Internet: Quienes tienen conexión a internet alcanzan 21.81 puntos más que aquellos sin conexión, manteniendo constantes las demás variables.

Habitación propia: Sorprendentemente, los estudiantes con habitación propia obtienen 7.37 puntos menos que aquellos sin ella, manteniendo constantes las demás variables.

Género: Los hombres obtienen 10.60 puntos más que las mujeres en matemáticas, manteniendo constantes las demás variables.

Interpretación de las Métricas del Modelo

Significancia estadística: Todos los coeficientes son significativos (p-value < 0.05). Las variables más significativas son el índice ESCS, internet y género.

R2 ajustado = 0.1943: El modelo explica el 19.43% de la variabilidad en los puntajes de matemáticas. El 80.57% restante se atribuye a factores no incluidos en el modelo.

Conclusión

El modelo confirma que el índice ESCS es el predictor más fuerte del rendimiento en matemáticas. El acceso a computadora e internet tiene un impacto positivo y significativo. El resultado inesperado sobre la habitación propia merece mayor investigación, y se identifica una brecha de género que favorece a los hombres.

Evaluación de los supuestos en la regresión Lineal Multiple

El siguiente paso es estimar el BEST LINEAR UNBIASED ESTIMATED (BLUE) buscando minimizar el error de la varianza y el sesgo.

1)Normalidad

Para verificar el supuesto de normalidad de los residuos procederé a:

1. Aplicar la prueba de Anderson-Darling (seleccionada por ser mas mas potente con muestras grandes como la nuestra de 12.111 observaciones).
2. Visualizar la distribución mediante un histograma con curva normal.
3. Analizar el gráfico de de QQ plot de los residuos.

1.Anderson-Darling Test

Formulo las siguientes hipótesis:

Ho : Los datos tienen una distribución normal

H1 : Los datos No tienen una distribución normal

```
##
##  Anderson-Darling normality test
##
## data:  residuos
## A = 3.0662, p-value = 0.0000001084
```

Según es test el valor-p es menor al nive de significancia (0.05) por lo tanto se rechaza la hipótesis nula llegando a la conclusión en que hay evidencia suficiente para concluir que los datos no se distribuyen en forma normal.

2. Histograma

```
##      Min.   1st Qu.    Median      Mean   3rd Qu.      Max.
## -248.2655  -46.5024   -0.7257    0.0000   44.8722  259.1437
```

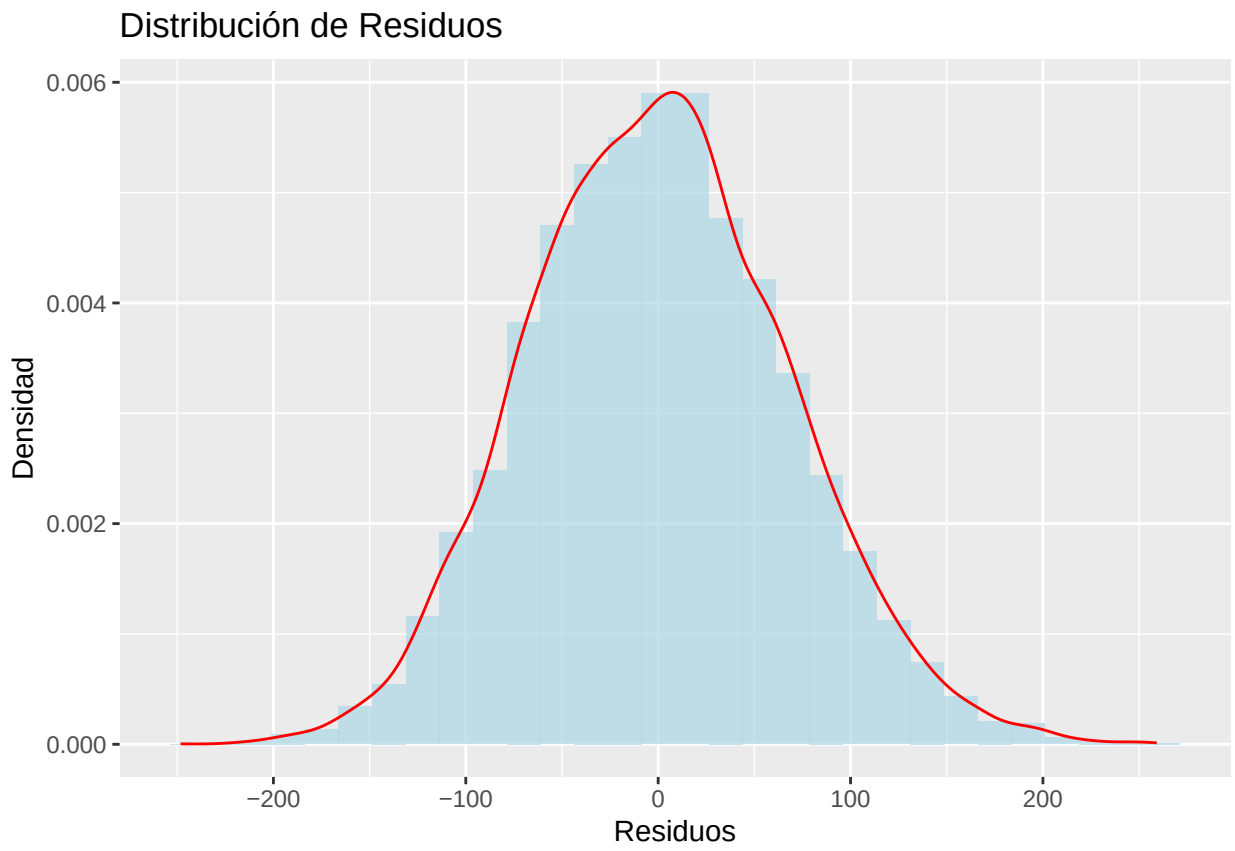


Figura 14. El histograma muestra un leve sesgo a la derecha. Dado que esta desviación es sutil, podríamos considerar el supuesto de normalidad como razonablemente válido. Para confirmarlo, analicemos el gráfico Q-Q normal: si los residuos siguen una distribución normal, los puntos se alinearán aproximadamente sobre la línea recta de referencia.

3. QQplot

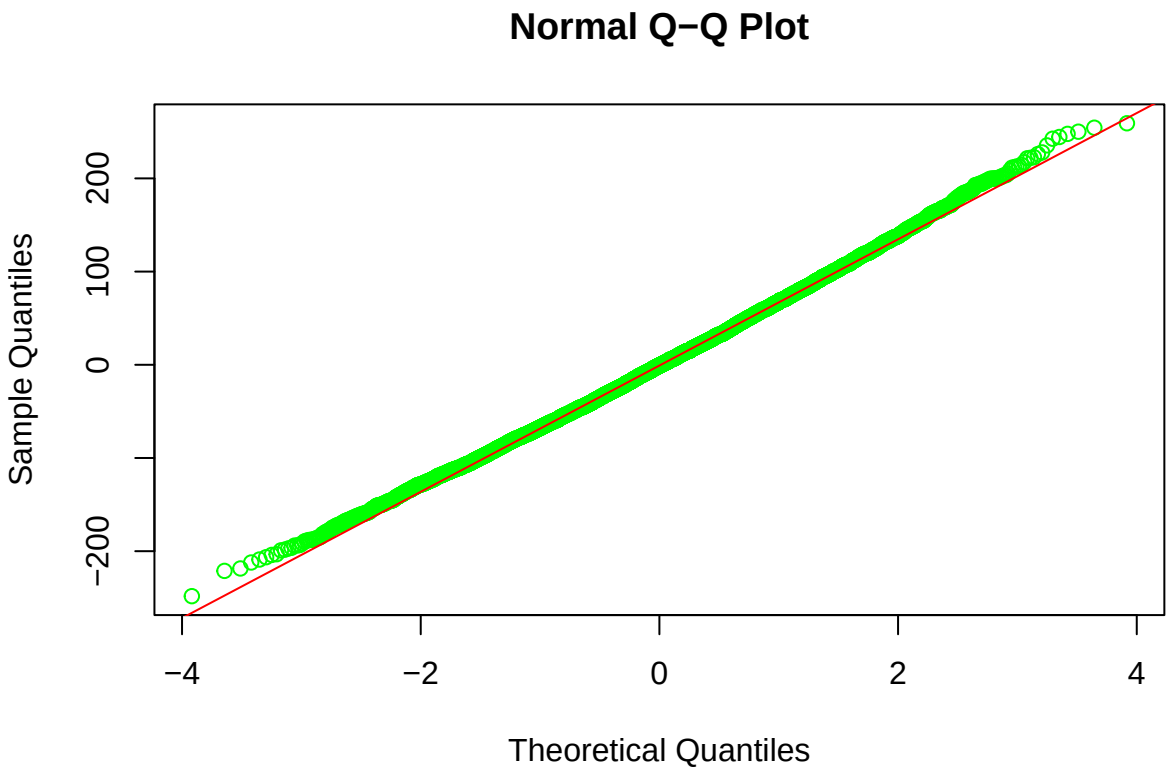


Figura 15. En el gráfico podemos observar que la mayoría de los residuos se situan en una linea recta, solo desviándose en los extremos. Entonces podemos suponer que los residuos del modelo siguen una distribución normal aceptable.

Por lo tanto el modelo cumple con el supuesto de Normalidad.

2) Linealidad La linearidad implica que existe una relación lineal entre la variable independiente x y la variable dependiente y. Los cambios en X se traducen en cambios proporcionales en y.

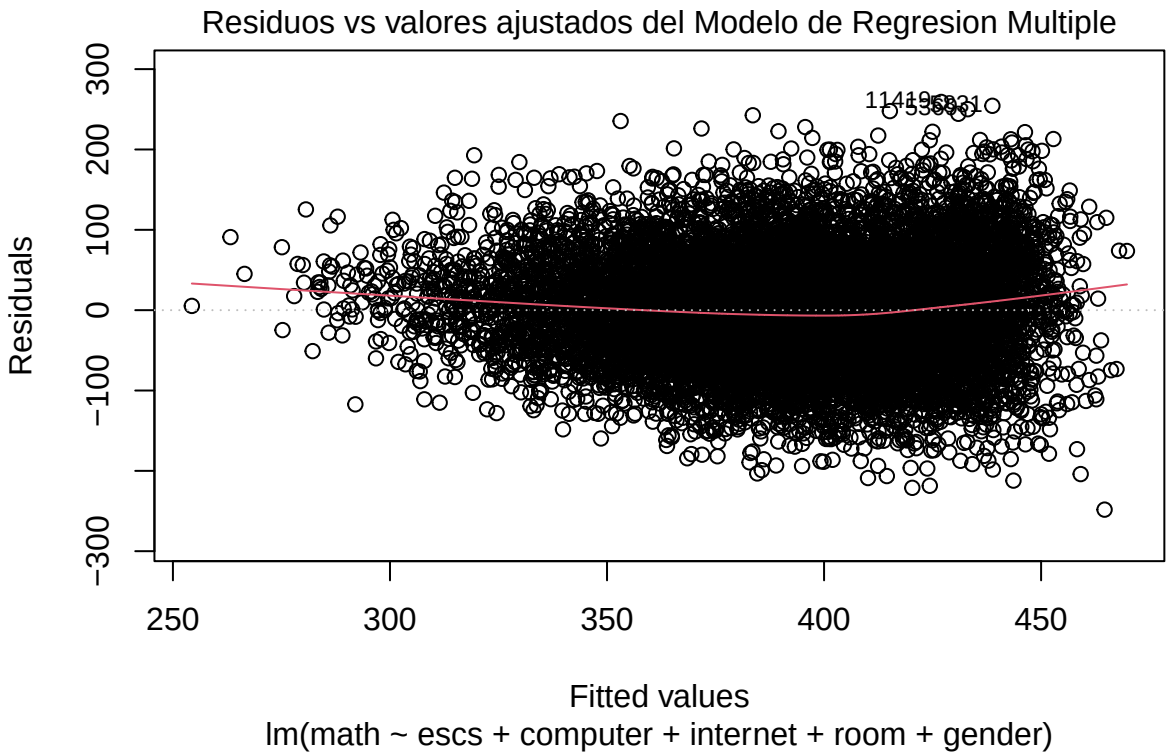


Figura 16. En el gráfico observamos el relación entre las variables predictoras mostrando los residuos versus los valores ajustados.

```
##
##  RESET test
##
## data:  modelo_mul
## RESET = 72.022, df1 = 2, df2 = 11186, p-value < 0.00000000000000022
```

La prueba Ramsey RESET presenta un p-value < 0.05 indicando que se rechaza la hipótesis nula implicando la inexistencia de una relacion lineal entre la variable independiente y la variable dependiente por lo tanto nuestros estimadores estarán sesgados.

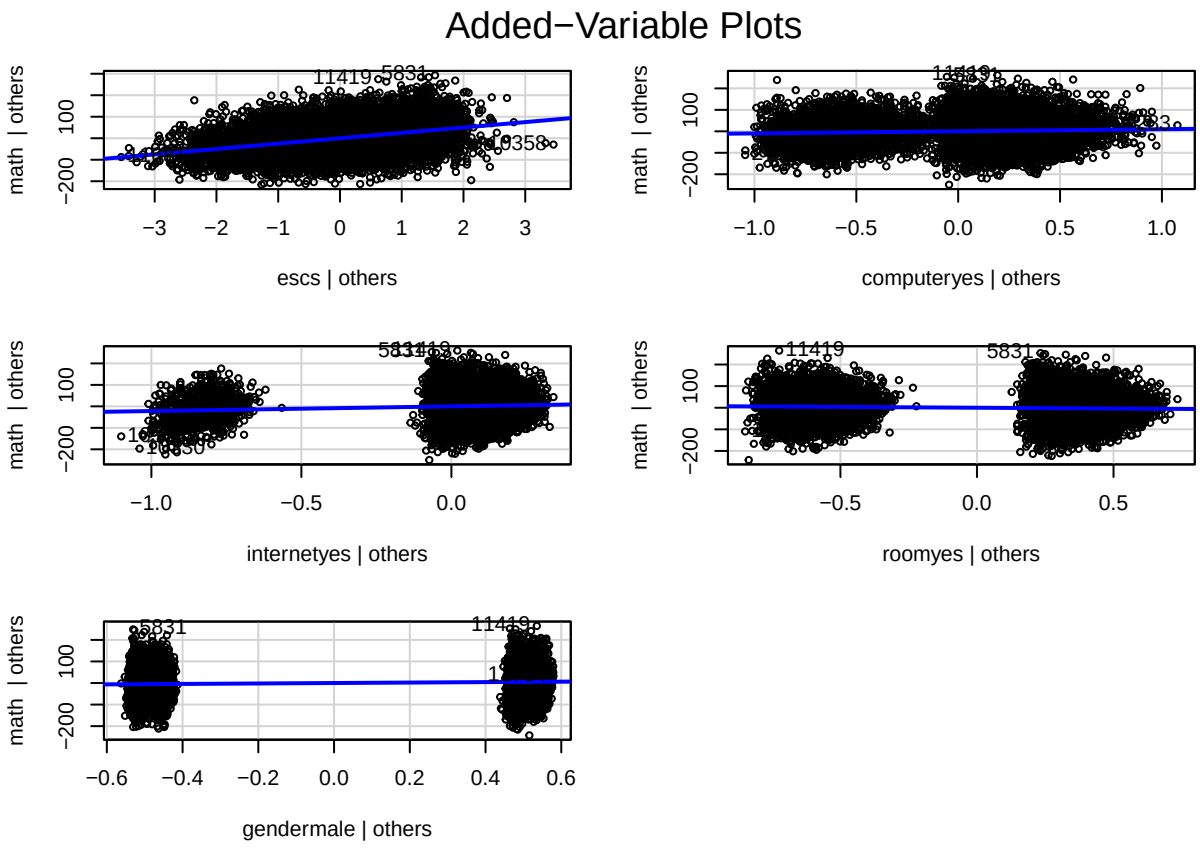


Figura 17

En el gráfico de la fig. 17 podemos observar mucha varianza en cada una de las variables independientes del modelo por lo tanto ni hay una relación lineal precisa Esto implica que el modelo no es capaz de relacionar adecuadamente las variables predictoras con la variable independiente, lo que conlleva a subajuste o sobreajuste. Para agregar linealidad al modelo se puede realizar alguna transformación logarítmica o cuadrática en algunas de las variables independientes.

Transformaciones del modelo

Veamos si mejora aplicando una transformación logarítmica.

```
##
## Call:
## lm(formula = math ~ log(escs) + computer + internet + room +
##     gender, data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -246.646  -51.345   -0.013   49.473  260.589
##
## Coefficients:
##             Estimate Std. Error t value             Pr(>|t|)
## (Intercept)  344.491     12.245  28.132 < 0.0000000000000002 ***
## log(escs)     15.456      1.262  12.243 < 0.0000000000000002 ***
## computeryes   17.558      4.559   3.852             0.000119 ***
```

```
## internetyes   80.514     11.604   6.938     0.00000000000469 ***
## roomyes       -5.227      2.789  -1.874             0.060955 .
## gendermale    12.696      2.438   5.207     0.00000020247553 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 73.19 on 3611 degrees of freedom
##   (8494 observations deleted due to missingness)
## Multiple R-squared:  0.0718, Adjusted R-squared:  0.07051
## F-statistic: 55.86 on 5 and 3611 DF,  p-value: < 0.00000000000000022

##
##  RESET test
##
## data:  modelo_mejorado_1
## RESET = 37.125, df1 = 2, df2 = 3609, p-value < 0.00000000000000022
```

Veamos si mejora aplicando una transformación Polinominal.

```
##
## Call:
## lm(formula = math ~ escs + I(escs^2) + computer + internet +
##     room + gender, data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -269.592  -46.392   -1.091   44.017  260.553
##
## Coefficients:
##             Estimate Std. Error t value             Pr(>|t|)
## (Intercept) 372.7249     2.9578 126.015 < 0.0000000000000002 ***
## escs         31.7705     0.8845  35.920 < 0.0000000000000002 ***
## I(escs^2)     4.6588     0.4191  11.117 < 0.0000000000000002 ***
## computeryes  10.0690     1.5558   6.472       0.000000000101 ***
## internetyes  26.7791     2.4872  10.767 < 0.0000000000000002 ***
## roomyes      -7.9452     1.3409  -5.925       0.000000003213 ***
## gendermale   11.2595     1.2718   8.853 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 67.09 on 11187 degrees of freedom
##   (917 observations deleted due to missingness)
## Multiple R-squared:  0.2035, Adjusted R-squared:  0.2031
## F-statistic: 476.4 on 6 and 11187 DF,  p-value: < 0.00000000000000022

##
##  RESET test
##
## data:  modelo_mejorado_2
## RESET = 17.939, df1 = 2, df2 = 11185, p-value = 0.00000001665

##
## Call:
```

```
## lm(formula = log(math) ~ escs + I(escs^2) + computer + internet +
##     room + gender, data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.80450 -0.11123  0.01163  0.12175  0.52024
##
## Coefficients:
##              Estimate Std. Error t value             Pr(>|t|)
## (Intercept)  5.899406   0.007680 768.189 < 0.0000000000000002 ***
## escs         0.077078   0.002297  33.563 < 0.0000000000000002 ***
## I(escs^2)    0.009825   0.001088   9.030 < 0.0000000000000002 ***
## computeryes  0.024665   0.004039   6.106 0.000000001055553097 ***
## internetyes  0.076358   0.006458  11.824 < 0.0000000000000002 ***
## roomyes     -0.021440   0.003482  -6.158 0.000000000761575761 ***
## gendermale   0.027043   0.003302   8.189 0.000000000000000291 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1742 on 11187 degrees of freedom
##   (917 observations deleted due to missingness)
## Multiple R-squared:  0.1951, Adjusted R-squared:  0.1947
## F-statistic:   452 on 6 and 11187 DF,  p-value: < 0.00000000000000022


##
##  RESET test
##
## data:  modelo_mejorado_3
## RESET = 12.858, df1 = 2, df2 = 11185, p-value = 0.000002644
```

Mejoró un poco pero aun el p-value es menor a 0.05

Por lo tanto, tras aplicar diversas transformaciones a las variables, se puede concluir que el supuesto de linealidad no se cumple en el modelo. La relación entre las variables, incluso después de las transformaciones, no es lineal.

3) INDEPENDENCIA En este supuesto las variables predictoras no tiene que estar influenciadas por la variable dependiente ni por los errores del modelo. Mirando el gráfico (figura 18) vemos que no existe un patron aleatorio por lo tanto cumple con el supuesto de independencia.

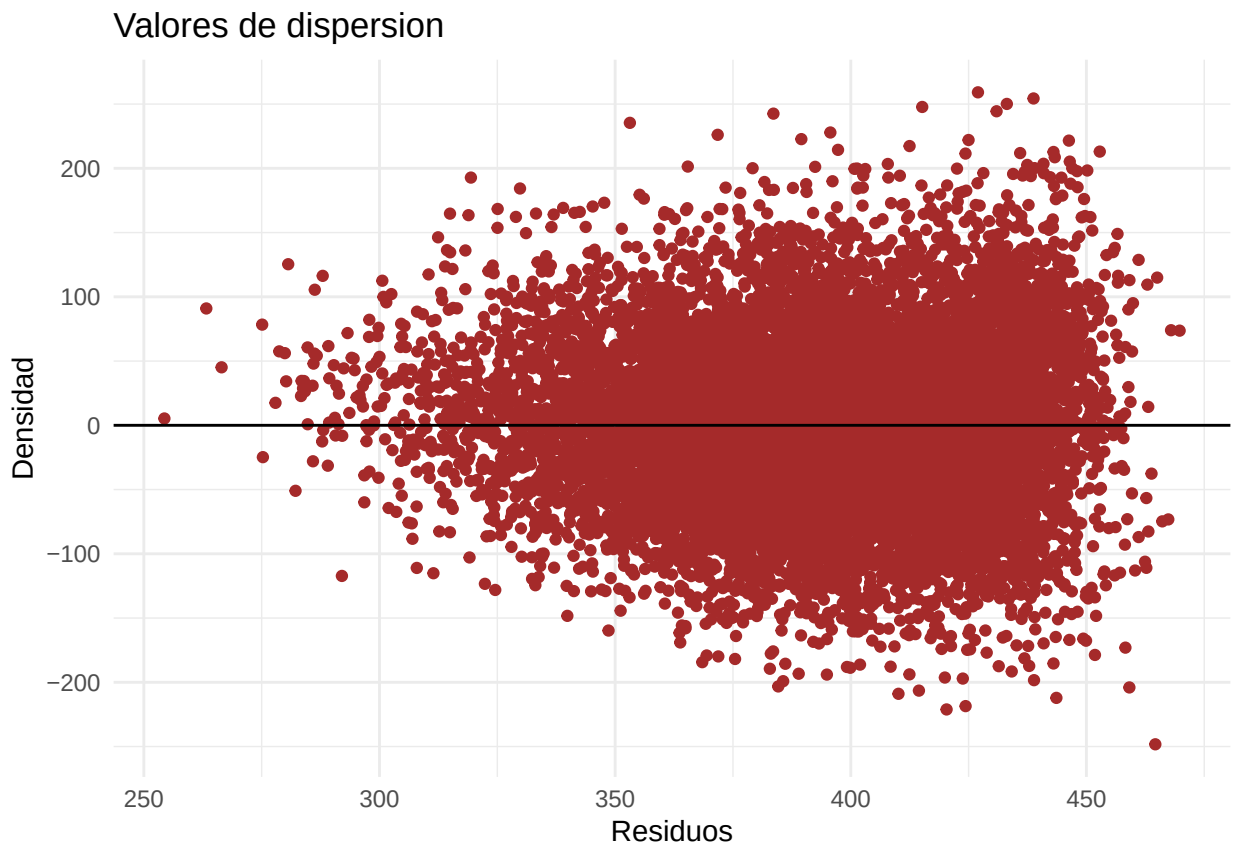


Figura 18

4)HETEROCEIDAD Existe Heteroceidad cuando los residuos del modelo tienen una dispersion constante independientemente del valor de X. Usando la prueba de White, se encuentra evidencia de heterocedasticidad en el modelo.

Formulo las siguientes hipótesis:

Ho : Hay Homocedasticidad

H1 : Hay Heterocedasticidad

```
## White's test results
##
## Null hypothesis: Homoskedasticity of the residuals
## Alternative hypothesis: Heteroskedasticity of the residuals
## Test Statistic: 155.9
## P-value: 0
```

Usando la prueba de White, vemos que el valor de p es o por lo tanto es menor a 0.05 por lo tanto rechazamos la hipótesis nula de homocedasticidad y aceptamos la hipótesis alternativa de heteroceidad.

Transformaciones del modelo

Aplicaremos una estrategia para resolver el problema.

```
##
```

```
## Call:
## lm(formula = log(math) ~ escs + I(escs^2) + computer + internet +
##     room + gender, data = muestra_linea)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.80450 -0.11123  0.01163  0.12175  0.52024
##
## Coefficients:
##              Estimate Std. Error t value             Pr(>|t|)
## (Intercept)  5.899406   0.007680 768.189 < 0.0000000000000002 ***
## escs         0.077078   0.002297  33.563 < 0.0000000000000002 ***
## I(escs^2)    0.009825   0.001088   9.030 < 0.0000000000000002 ***
## computeryes  0.024665   0.004039   6.106 0.000000001055553097 ***
## internetyes  0.076358   0.006458  11.824 < 0.0000000000000002 ***
## roomyes     -0.021440   0.003482  -6.158 0.000000000761575761 ***
## gendermale   0.027043   0.003302   8.189 0.000000000000000291 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1742 on 11187 degrees of freedom
##   (917 observations deleted due to missingness)
## Multiple R-squared:  0.1951, Adjusted R-squared:  0.1947
## F-statistic:   452 on 6 and 11187 DF,  p-value: < 0.00000000000000022
```

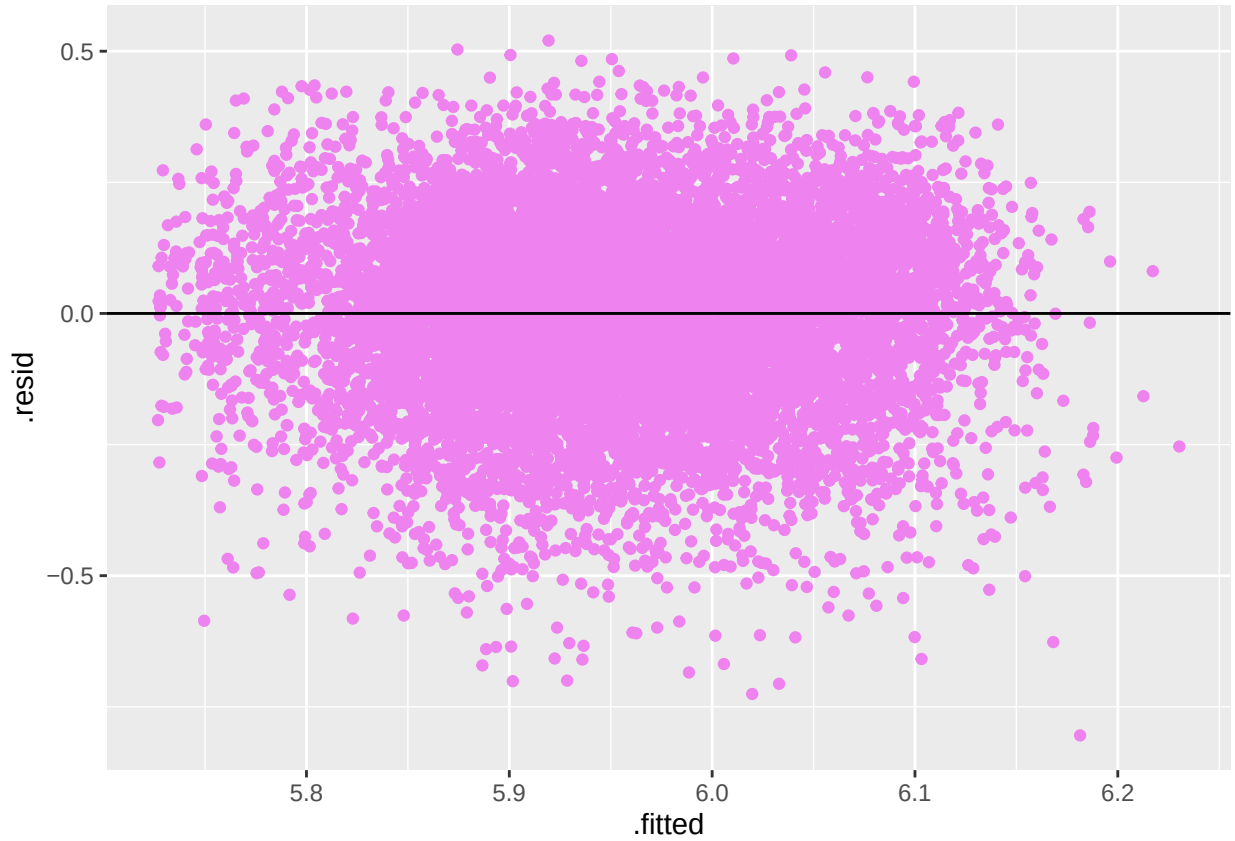


Figura 19 El gráfico de residuos vs. valores ajustados muestra que los puntos se distribuyen de forma aleatoria alrededor del cero.

```
## White's test results
##
## Null hypothesis: Homoskedasticity of the residuals
## Alternative hypothesis: Heteroskedasticity of the residuals
## Test Statistic: 1.45
## P-value: 0.484946
```

Aplicando la estrategia de transformacion del modelo concluimos que no existe evidencia suficiente que hay heterocedasticidad en los residuos del modelo por lo tanto el supuesto de Homocedasticidad se cumple.

5) NO AUTOCORRELACION Este supuesto indica que los residuos de un modelo de regresión son independientes entre si no existiendo unun patrón sistemático en los residuos. La revisión de este supuesto no aplica al modelo debido a la inexistencia de mediciones repetidas y datos temporales.

Test de hipótesis:

Para la formulación del test de hipótesis, se seleccionó la puntuación de Matemáticas del año 2022 con el fin de compararla con los resultados del año 2015.

Formulación de Hipótesis:

H0 = No existe diferencia en la puntuacion de Matematica entre el 2015 y 2022 H1 = Si existe diferencia en la puntuacion de Matematica entre el 2015 y 2022

Se utilizo la base de datos de Estudiantes del año 2015 y 2022.

```
## # A tibble: 519,334 x 2
##     year  math
##    <int> <dbl>
##  1  2015  463.
##  2  2015  430.
##  3  2015  303.
##  4  2015  337.
##  5  2015  291.
##  6  2015  392.
##  7  2015  485.
##  8  2015  294.
##  9  2015  362.
## 10  2015  386.
## # i 519,324 more rows
```

La base de datos Estudiantes 2015 tiene 519.334 observaciones y 2 variables.

```
## [1] 519334      2
```

La base de datos Estudiantes 2022 tiene 613.744 observaciones y 2 variables.

```
## [1] 613744      2
```

```
## # A tibble: 1,133,078 x 2
##     year  math
##    <int> <dbl>
##  1  2015  463.
```

```
##  2  2015  430.
##  3  2015  303.
##  4  2015  337.
##  5  2015  291.
##  6  2015  392.
##  7  2015  485.
##  8  2015  294.
##  9  2015  362.
## 10  2015  386.
## # i 1,133,068 more rows
```

```
## # A tibble: 2 x 7
##    year      n mean_score sd_score min_score max_score var_score
##   <int>  <int>      <dbl>    <dbl>     <dbl>     <dbl>     <dbl>
## 1  2015 519334       463.     103.         0      871.    10660.
## 2  2022 613744       441.     102.         0      943.    10372.
```

Comparación de Puntajes por Año

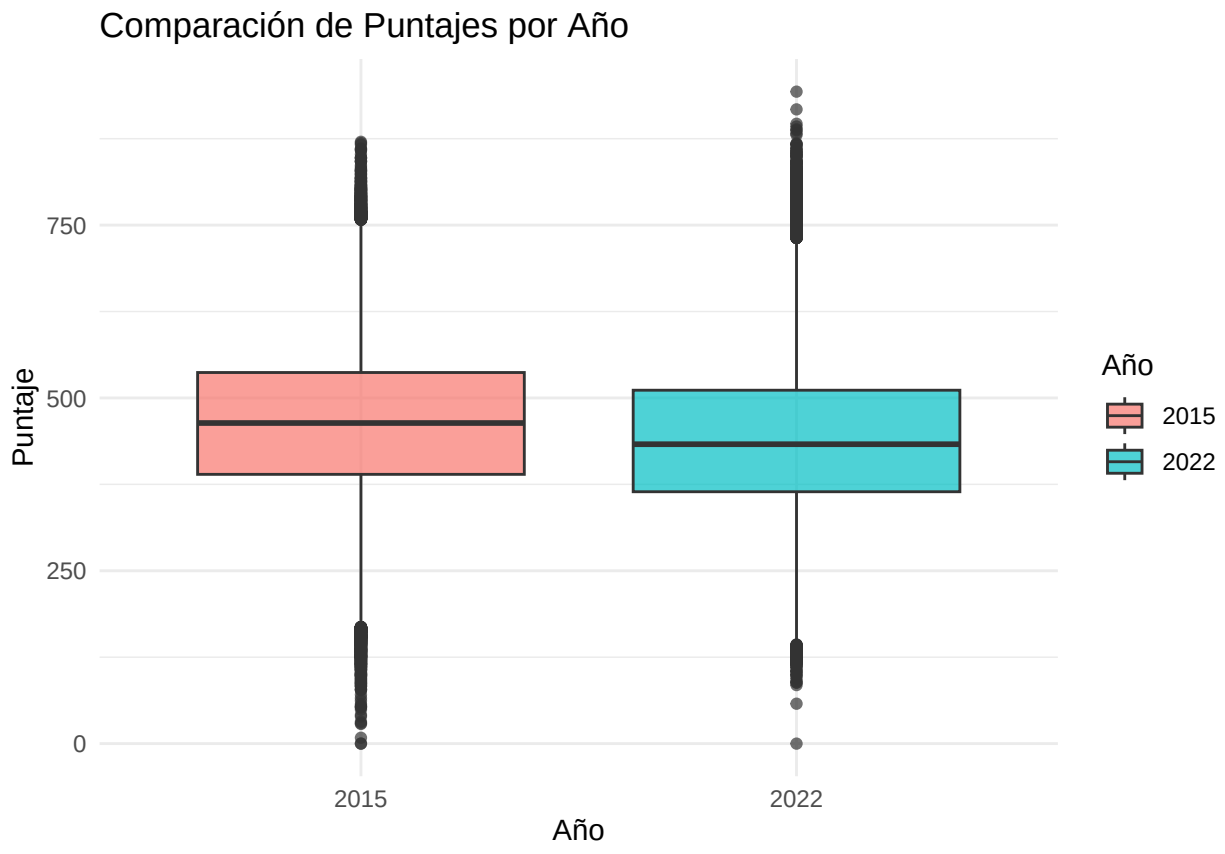


Figura 20

En el gráfico de la fig. 20 podemos observar que la mediana de la puntuación de Matemática en 2015 fue mayor que la del año 2022. Ambas muestras presentan datos atípicos en valores máximos y mínimos.

Distribución de Puntajes por Año

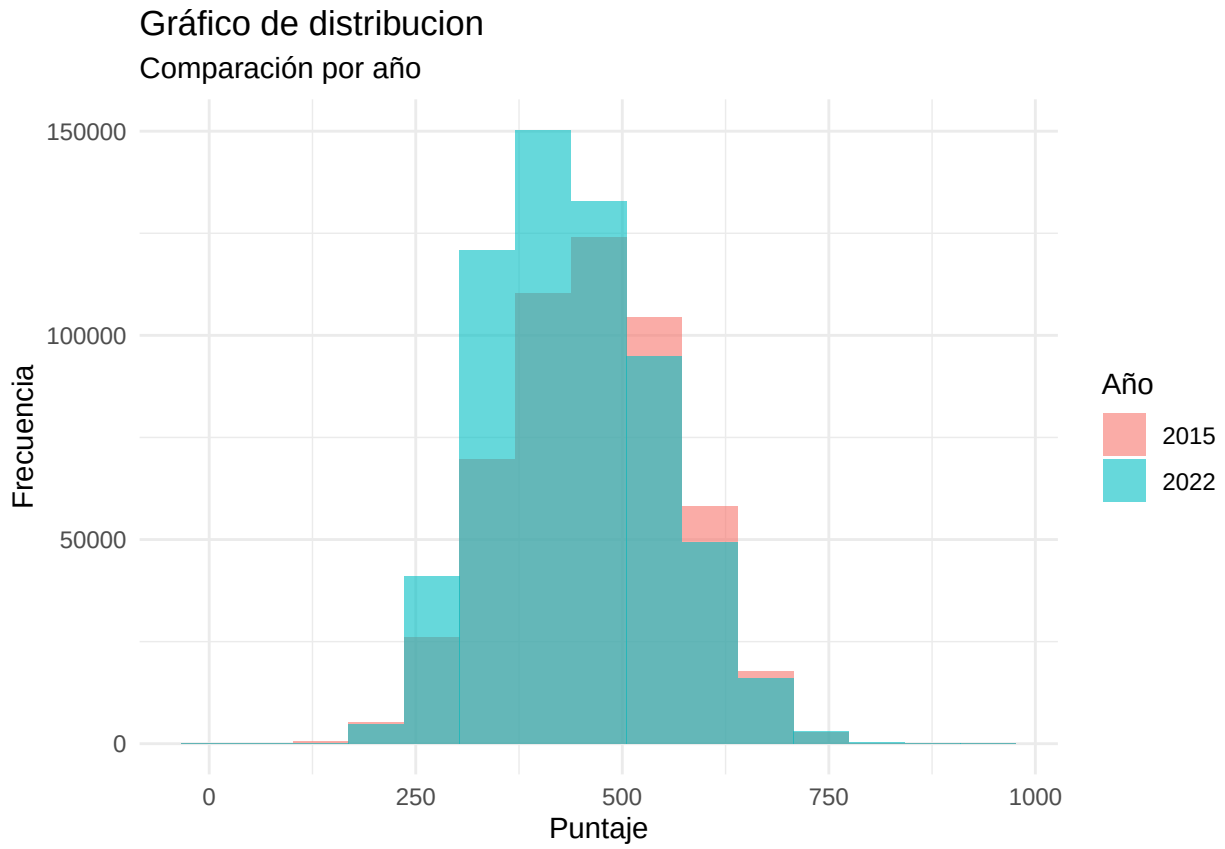


Figura 21.

La Figura 21 muestra, mediante un histograma, que la distribución de la puntuación en Matemáticas en el año 2018 se aproxima más a una distribución normal en comparación con el año 2015.

Realizamos la prueba de normalidad;

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  math by year
## W = 180865144592, p-value < 0.00000000000000022
## alternative hypothesis: true location shift is not equal to 0
```

De acuerdo con los resultados, se identificó que los datos no siguen una distribución normal, mostrando asimetría en su distribución. Por lo tanto, para comparar los grupos, se utilizó la prueba de Wilcoxon o Mann-Whitney.

Conclusión

La prueba de Wilcoxon rank indicó que la diferencia entre los grupos fue estadísticamente significativa ($W = 180865144592$, $p < 0.05$). Por lo tanto, se rechaza la hipótesis nula, concluyendo que existe una diferencia significativa en las distribuciones de los dos grupos.

Comentarios Finales

Este proyecto tuvo como objetivo analizar comparativamente el rendimiento educativo y su relación con factores socioeconómicos en cuatro países: Argentina, Irlanda, Corea del Sur y Nueva Zelanda. Los principales hallazgos confirman la existencia de notables disparidades educativas a nivel global.

Resumen de Hallazgos Principales:

- Rendimiento por País: Se identificaron marcadas diferencias en el desempeño académico. Corea del Sur demostró los niveles más altos en las tres áreas evaluadas, especialmente en matemáticas. Irlanda y Nueva Zelanda mostraron rendimientos similares en ciencias, aunque Irlanda obtuvo ventajas en matemáticas y lectura. Argentina, por su parte, presentó los puntajes más bajos del grupo, con una brecha particularmente pronunciada en matemáticas.
- Relación ESCS-Rendimiento: El análisis reveló una correlación positiva consistente entre el índice de estatus socioeconómico y cultural (ESCS) y el rendimiento académico en todos los países. Esta relación fue más fuerte en Argentina, específicamente en el área de matemáticas, lo que motivó un análisis más profundo en este contexto.
- Modelo de Regresión Múltiple: Para el caso de Argentina, la implementación de un modelo de regresión múltiple permitió aislar el efecto individual de cada variable. Los resultados confirmaron que el índice ESCS es el predictor más sólido del rendimiento en matemáticas. Asimismo, el acceso a computadora e internet mostró un impacto positivo y significativo. Dos hallazgos destacables fueron: a) la identificación de una brecha de género que favorece a los estudiantes hombres, y b) el resultado inesperado respecto a la variable "habitación propia", cuyo efecto merece ser investigado con mayor profundidad.
- Prueba de Hipótesis: Finalmente, la prueba de hipótesis aplicada confirmó que existe una diferencia estadísticamente significativa entre el rendimiento en matemáticas de las evaluaciones PISA del 2015 y las del 2022.

Conclusión Final

En síntesis, esta investigación evidencia la profunda influencia del contexto socioeconómico en los resultados educativos, con variaciones significativas entre países. Los hallazgos subrayan la necesidad de políticas educativas que aborden las desigualdades de base y aprovechen el potencial de la tecnología como herramienta de equidad. El caso de Argentina resalta la urgencia de intervenciones focalizadas para mitigar el impacto de la desventaja socioeconómica en el desempeño académico, particularmente en matemáticas.